

TalentMatch

Comment ça marche ?

Explication simple du système d'extraction et de matching IA

Document :	Explication du modèle de matching
Réalisé par :	Youssef Gara
Entreprise :	3S Group — Tunis
Date :	Juin 2026

1. TalentMatch en quelques mots

TalentMatch est une plateforme qui **lit automatiquement un CV** et le compare à une offre d'emploi pour calculer un **score de compatibilité** entre 0 et 100%.

Le but : aider le recruteur à trouver les meilleurs candidats rapidement, sans lire des dizaines de CVs manuellement.

Analogie : Imaginez un assistant très intelligent qui lit tous les CVs à votre place, comprend ce que chaque candidat sait faire, et vous dit : « Ce candidat correspond à 87% à votre offre, et voilà pourquoi. »

■ Le pipeline en 3 grandes étapes

1	Extraction Lire le CV et en extraire le texte brut, quelle que soit sa forme (PDF, Word, scan).
2	Parsing NLP Comprendre le texte et identifier les compétences, expériences, formations du candidat.
3	Matching IA Comparer le profil du candidat avec l'offre d'emploi et calculer un score 0–100%.

2. Étape 1 — Lire le CV (Extraction)

Un CV peut arriver sous plusieurs formats. TalentMatch sait lire chacun d'eux grâce à des outils spécialisés.

■ Les 3 types de CV et comment on les lit

PDF texte	<i>Le type le plus courant.</i>
Outil : PyMuPDF / pypdf	On lit directement le texte contenu dans le fichier PDF, comme un copier-coller.
Fichier Word (.docx)	<i>Créé avec Microsoft Word.</i>
Outil : python-docx	On lit le document Word et on en extrait le texte paragraphe par paragraphe.
PDF scanné / Image	<i>Un CV photographié ou scanné. Il n'y a pas de texte, juste une image.</i>
Outil : EasyOCR	On utilise la reconnaissance optique de caractères (OCR) : le logiciel analyse l'image et reconnaît les lettres, comme un humain qui lit une photo.
A retenir : Après cette étape, on a du texte brut, mais on ne sait pas encore ce que ça veut dire. C'est le rôle de l'étape suivante.	

3. Étape 2 — Comprendre le CV (Parsing NLP)

NLP signifie **Traitement du Langage Naturel**. C'est la capacité d'un ordinateur à comprendre du texte écrit par un humain.

Cette étape transforme le texte brut du CV en une **fiche structurée** : on sait exactement quelles compétences le candidat a, combien d'années il a travaillé, quel diplôme il possède, etc.

Analogie : C'est comme si quelqu'un lisait un CV et remplissait un formulaire : Nom, Compétences, Expériences, Formations. Au lieu d'une personne, c'est un programme informatique qui le fait automatiquement.

■ Ce qu'on extrait du CV

Identité

- Nom complet
- Email
- Téléphone
- Adresse

Compétences

- Techniques : Python, React, SQL, Docker...
- Soft skills : Leadership, Communication...

Expériences

- Intitulé du poste
- Nom de l'entreprise
- Durée en mois/années

Formations

- Diplôme obtenu
- Établissement
- Année d'obtention

Langues

- Français, Anglais, Arabe — avec niveau détecté automatiquement

A retenir : À la fin de cette étape, chaque CV devient une fiche JSON structurée stockée en base de données. Exemple : { compétences: ['React', 'Python'], expérience: 3 ans, diplôme: 'Licence' }.

■ L'outil utilisé : spaCy

spaCy est une bibliothèque Python spécialisée dans la compréhension du texte. Elle a été entraînée sur des millions de textes français pour reconnaître les noms de personnes, les organisations, les dates, les lieux, etc.

On utilise le modèle **fr_core_news_md** — un modèle pré-entraîné sur du français. Il fonctionne entièrement sur l'ordinateur local, sans connexion internet.

4. Étape 3 — Le Matching IA

C'est le cœur de TalentMatch. On compare le profil du candidat avec l'offre d'emploi et on calcule un **score de compatibilité entre 0 et 100%**.

Le matching se fait en **3 niveaux**, chacun apportant plus de précision que le précédent.

■ Niveau 1 — BGE-M3 : comprendre le sens des textes

BGE-M3 est un modèle d'intelligence artificielle développé par des chercheurs chinois (Beijing Academy of Artificial Intelligence). Il a été entraîné sur des milliards de phrases dans plus de 100 langues, dont le français et l'arabe.

Son rôle : transformer chaque texte (le CV et l'offre) en un **vecteur numérique** — une liste de 1024 chiffres qui représente le « sens » du texte.

Analogie : Imaginez une carte géographique où chaque texte est un point. Deux textes qui parlent de la même chose sont proches sur la carte. BGE-M3 place le CV et l'offre sur cette carte, et on mesure la distance entre eux. Plus ils sont proches, plus le candidat correspond à l'offre.

Pourquoi BGE-M3 et pas un simple comptage de mots-clés ?

- Un comptage de mots-clés raterait : « développeur web » ≠ « React developer » alors que c'est le même métier.
- BGE-M3 comprend que React, JavaScript et développeur frontend sont des concepts proches.
- Il fonctionne en français, anglais et arabe en même temps — idéal pour les CVs tunisiens.

■ Niveau 2 — Cross-Encoder : affiner la comparaison

Le Cross-Encoder est un deuxième modèle IA. Il lit le CV et l'offre **en même temps**, dans le même passage, au lieu de les analyser séparément.

Analogie : Si BGE-M3 est comme comparer deux résumés de livres séparément, le Cross-Encoder est comme lire les deux livres côte à côte, chapitre par chapitre, pour trouver les correspondances précises.

Résultat : un score de similarité plus précis, qui tient compte des interactions entre les phrases du CV et de l'offre.

Limitation : c'est plus lent car il doit tout relire à chaque fois. C'est pourquoi on l'utilise seulement pour affiner le résultat de BGE-M3.

■ Niveau 3 — MLP Fusion : combiner tout pour un score final

MLP signifie **Multi-Layer Perceptron** — c'est un petit réseau de neurones qu'on a entraîné spécialement pour TalentMatch.

Il prend **7 informations** sur le candidat et l'offre, et les combine intelligemment pour produire le score final.

■ Les 7 informations utilisées pour le score

#	Information	Ce que ça mesure	Exemple
1	Score sémantique	À quel point le CV parle des mêmes sujets que l'offre	Cv React + offre React → score élevé
2	Compétences communes	Combien de compétences requises le candidat possède	8 compétences requises → 80%
3	Années d'expérience	L'expérience du candidat correspond-elle à ce qu'on demande ?	Offre : 8 ans exp. Candidat a 5 ans → match
4	Niveau d'études	Le diplôme du candidat est-il suffisant ?	Offre : Licence min. Candidat : Master → OK
5	Domaine professionnel	Le métier du candidat est-il le même que l'offre ?	Devloppeur ↔ Offre Dev → même domaine
6	Nombre de compétences	Le candidat a-t-il assez de compétences ?	Candidat : 15 compétences vs offre qui en demande 10
7	Mots-clés de l'offre	Les mots importants de l'offre sont-ils dans le CV ?	« dans l'offre Docker » et le CV mentionne Docker

Analogie : Le MLP Fusion, c'est comme un jury de 7 experts : chacun donne une note sur un aspect différent du candidat. Le MLP a appris (grâce à l'entraînement) le poids à donner à chaque expert pour arriver au meilleur score final possible.

A retenir : Le MLP a été entraîné sur plus de 1380 paires (candidat, offre) avec des notes calculées automatiquement. Il a appris tout seul comment combiner les 7 informations pour donner le meilleur score.

5. La vérification du domaine professionnel (ISCO-08)

Avant de calculer le score final, TalentMatch vérifie si le candidat et l'offre sont dans le **même domaine professionnel**.

On utilise la classification **ISCO-08** — une liste officielle de l'ONU qui regroupe tous les métiers du monde en 53 grandes catégories.

Analogie : C'est comme des rayons dans un supermarché : si l'offre cherche un développeur (rayon Informatique) et que le CV est d'un médecin (rayon Santé), le score maximum est automatiquement limité, même si les textes se ressemblent.

Situation	Score maximum possible	Exemple
Même domaine	100% (aucune limite)	Dev React ↔ Offre React
Domaines proches	65% maximum	Data Scientist ↔ Dev Backend
Domaines différents	35% maximum	Médecin ↔ Offre Développeur

A retenir : Cette règle évite qu'un très bon rédacteur de CV (qui utilise les bons mots-clés) obtienne un score élevé pour un poste qui ne correspond pas du tout à son domaine.

6. Le score final — comment l'interpréter ?

Le score final est affiché en pourcentage (0–100%) dans l'interface TalentMatch. Voici comment l'interpréter :

Score	Interprétation	Couleur affichée
80% – 100%	Excellent match. Le candidat correspond très bien à l'offre.	Vert
60% – 79%	Bon match. Le profil est pertinent, avec quelques écarts mineurs.	Vert clair
40% – 59%	Match moyen. À étudier selon le contexte.	Orange
20% – 39%	Faible correspondance. Profil probablement hors cible.	Rouge clair
0% – 19%	Pas de correspondance. Domaine différent ou profil incompatible.	Rouge

■ Ce que le recruteur voit en plus du score

- **Compétences présentes** : la liste des compétences requises que le candidat possède déjà.
- **Compétences manquantes** : ce qu'il lui manque pour parfaitement correspondre.
- **Décomposition par dimension** : quel sous-score pour les compétences, l'expérience, la formation et la sémantique.
- **Rapport IA** : un texte généré automatiquement qui explique en langage naturel pourquoi le candidat correspond ou non.

7. Résumé — Le pipeline complet en un coup d'œil

Étape	Quoi ?	Comment ?	Outil
1 — Réception	Recevoir le CV	Upload via l'interface web	React + FastAPI
2 — Extraction	Lire le texte du CV	Selon le format : direct, Word ou ODT	PyMuPDF / python-docx / EasyOCR
3 — Parsing NLP	Identifier compétences, expériences, formations et sémiotique	Analyses morphologiques et sémantiques	spaCy / nltk / core_news_md
4 — Stockage	Sauvegarder le profil structuré	Enregistrement en base de données	PostgreSQL (JSONB)
5 — Embeddings	Transformer CV et offre de travail en plongées	Modèle entraîné avec 56M paramètres	BGE-M3 (BAAI)
6 — Score sémantique	Mesurer la similarité sémantique précise	Recherche de similarité	Cross-Encoder (BAAI)
7 — Score final	Combiner les 7 dimensions	Réseau de neurones entraîné sur 1800 paires	1800-Pairs (PyTorch)
8 — Résultat	Afficher le classement et l'interface de détail	Interface de détail avec explication	React + MatchReport