

Module d'Évaluation Technique

« Reality Gap Score » — Entretien technique automatisé 100 % local

Plateforme 3S TalentMatch — Projet de Fin d'Études

Youssef GARA — Juillet 2026

Objet du document. Ce rapport explique le fonctionnement complet du module d'évaluation : une partie simple (pour tout lecteur), une partie technique détaillée, et une analyse Internet / confidentialité / RGPD. Il est destiné à la présentation du travail à l'encadrante et à l'entreprise.

Table des matières

1	Explication simple	2
1.1	À quoi sert le module ?	2
1.2	Le parcours en six étapes	2
1.3	Ce qui le distingue d'un simple quiz	2
2	Fonctionnement technique détaillé	2
2.1	Architecture	2
2.2	Génération des questions (100 % locale)	3
2.3	Test adaptatif (IRT / CAT)	3
2.4	Notation des réponses rédigées (sémantique)	4
2.5	Le « Reality Gap » (écart CV – démontré)	4
2.6	Le rapport IA	4
2.7	Sécurité et anti-triche	5
3	Internet, confidentialité et RGPD	5
3.1	Qu'est-ce qui utilise Internet ? (audit du code)	5
3.2	Analyse RGPD	6
3.3	Questions probables et réponses	6
3.4	Limites (honnêteté scientifique)	6

1 Explication simple

1.1 À quoi sert le module ?

Un CV *déclare* des compétences, mais rien ne prouve que le candidat les *maîtrise réellement*. Le module fait passer au candidat un **entretien technique automatisé** qui mesure son niveau réel, puis compare ce niveau à ce que son CV annonce.

En une phrase : le CV dit « Expert Python » — l'évaluation vérifie si c'est vrai.

1.2 Le parcours en six étapes

1. **Le recruteur** sélectionne un ou plusieurs candidats après le matching. Il peut ajouter ses propres questions et fixer une date d'ouverture et une date limite. Le lancement est **instantané**.
2. **L'IA locale** prépare le questionnaire de l'offre en arrière-plan (une seule fois par offre, environ 5 à 8 minutes ; réutilisé ensuite).
3. **Le candidat** reçoit un e-mail professionnel : lien personnel, code PIN à usage unique, dates de passage. *L'e-mail ne part que lorsque le questionnaire est prêt* — le candidat n'ouvre jamais un test vide.
4. Il se **connecte à son compte**, saisit le PIN, lit les **règles** puis passe le test en plein écran : environ 10 QCM adaptatifs (90 secondes chacun), 3 questions de raisonnement à rédiger, et les questions du recruteur.
5. **L'IA locale note tout** : niveau par compétence, qualité du raisonnement, écart entre le CV déclaré et le niveau démontré (« Reality Gap »).
6. **Le recruteur consulte** l'onglet « Évaluations » : niveau démontré /10, cohérence CV-test, radar « Déclaré vs Démontré », rapport rédigé par l'IA, toutes les réponses du candidat, et le score d'intégrité (anti-triche).

1.3 Ce qui le distingue d'un simple quiz

Aspect	Quiz classique	Notre module
Questions	Banque figée, écrite à la main	Générées par IA à partir de l'offre — fonctionne pour tout domaine (IT, finance, santé, droit...)
Difficulté	Identique pour tous	Adaptative (IRT) : converge vers le vrai niveau en ~10 questions
Rédaction	Non notée ou par mots-clés	Notée au <i>sens</i> par IA sémantique (BGE-M3)
Triche	Mêmes questions pour tous	Sous-ensemble différent par candidat, options mélangées, timer, télé-métrie
Résultat	Une note brute	Niveau par compétence + écart avec le CV + rapport IA + réponses vérifiables

2 Fonctionnement technique détaillé

2.1 Architecture

```

backend/app/
  routes/assessment.py          <- endpoints (20 routes)
  services/assessment/
    llm_client.py               <- client Ollama LOCAL (aucune API
      externe)
    question_generator.py       <- generation (paliers + auto-
      verification)
    question_bank.py            <- pool par offre, arriere-plan,
      invitations
    cat_engine.py               <- moteur IRT/CAT (catsim)
    semantic_scorer.py          <- notation semantique (BGE-M3,
      cosinus)
    reality_gap.py              <- ecart declare CV vs demontre
    report_generator.py         <- rapport IA (Ollama)
  models/assessment.py          <- 4 tables SQLAlchemy
frontend/src/
  components/AssessmentPanel.jsx <- lancement recruteur
  components/AssessmentsTab.jsx  <- onglet Evaluations (radar, rapport,
    reponses)
  pages/AssessmentCandidate.jsx  <- passage du test (PIN, regles, QCM,
    redaction)
  pages/MyAssessments.jsx        <- espace candidat "Mes Evaluations"

```

Tables PostgreSQL :

Table	Contenu
assessment_questions	Pool de QCM par offre (question, 4 options, bonne réponse, difficulté 1–10, paramètres IRT)
open_questions	Questions de raisonnement + 3 réponses de référence + embeddings
assessment_sessions	Une session par candidat : jeton, PIN, dates, questionnaire tiré, réponses, theta, scores, signaux d'intégrité
reality_gap_results	Écart déclaré/démontré par compétence, cohérence CV

2.2 Génération des questions (100 % locale)

Modèle : Mistral 7B via **Ollama** (serveur local <http://localhost:11434>).

Déclenchement : au premier lancement sur une offre, une tâche d'arrière-plan (FastAPI BackgroundTasks) génère le pool (~18 QCM + 6 questions rédigées). Le recruteur n'attend pas (lancement en 0,2s). Les lancements suivants sont immédiats.

Entrée du LLM : *uniquement* le titre du poste et les noms des compétences requises de l'offre (informations publiques). **Jamais le CV ni aucune donnée du candidat.**

Trois mécanismes de qualité :

1. **Paliers de difficulté :** deux appels séparés — moitié « fondamentaux » (difficulté 2–5), moitié « difficile/expert » (7–10 : pièges, cas limites).
2. **Distracteurs plausibles imposés :** quatre options proches, de même forme ; les mauvaises options sont des erreurs fréquentes du métier ⇒ deviner au hasard ne donne aucun indice.
3. **Auto-vérification :** le LLM répond lui-même à chaque QCM généré *sans voir* la réponse marquée ; en cas de désaccord, la question est rejetée.

2.3 Test adaptatif (IRT / CAT)

Théorie : *Item Response Theory*, le standard des tests standardisés (GMAT, TOEFL). Librairie : catsim.

- Chaque question possède des paramètres IRT : difficulté b (mappée de 1–10 vers $[-3, +3]$), discrimination a , pseudo-chance $c = 0,25$ (4 options).
- Le niveau du candidat est la variable θ (theta), initialisée à 0.
- À chaque réponse, θ est ré-estimé par maximum de vraisemblance, puis la question suivante est choisie parmi les plus *informatives* au niveau θ courant (sélecteur « randomesque » : tirage parmi les 5 meilleures, donc deux candidats de même niveau ne voient pas les mêmes questions).
- Le test s'arrête vers 10 questions ; θ est converti en niveau 0–10, avec un détail par compétence.

Pourquoi l'IRT plutôt qu'un pourcentage ? Un pourcentage dépend des questions posées (8/10 sur des questions faciles $\neq$ 8/10 sur des dures). θ estime le niveau indépendamment des questions : test court *et* comparaison équitable.

2.4 Notation des réponses rédigées (sémantique)

Modèle : BGE-M3 — le même modèle d'embeddings que le moteur de matching (instance partagée).

Chaque question rédigée possède trois réponses de référence (*faible*, *correcte*, *experte*) dont les vecteurs sont pré-calculés. À la soumission :

1. la réponse du candidat est encodée en vecteur (localement) ;
2. similarité cosinus avec chacune des trois références ;
3. score 0–100 par interpolation *softmax* vers les ancrs 25 / 62 / 95 ;
4. pénalité $\times 0,6$ si la réponse fait moins de 30 mots.

On note donc le **sens** de la réponse, pas des mots-clés. Validation expérimentale : experte $\approx 80 >$ correcte $\approx 41 >$ faible ≈ 16 .

Les **questions du recruteur** sont posées dans le même flux mais ne sont pas notées par l'IA : le recruteur les juge lui-même (souvent des questions de motivation sans « bonne réponse »).

2.5 Le « Reality Gap » (écart CV – démontré)

1. **Niveau déclaré** (0–10) dérivé du CV parsé, par compétence, avec une formule transparente : base 5 si la compétence est listée ; $+0,4/\text{année d'expérience indiquée}$ (plafond $+3$) ; $+2$ si utilisée dans une expérience réelle ; bonus séniorité ($+1$ confirmé, $+2$ senior). Absente du CV : 0.
2. **Écart** : $gap = |\text{déclaré} - \text{démontré}|/10$ par compétence, moyenne pondérée par l'importance dans l'offre (requis = 1,0 ; appréciée = 0,5).
3. **Cohérence CV** = $100 - gap \times 100$, avec les seuils : ≥ 85 « CV cohérent » ; 70–85 « à vérifier » ; < 70 « CV $\neq$ niveau démontré ».
4. **Score final ajusté** = $score_{\text{matching}} \times (0,7 + 0,3 \times \text{cohérence}/100)$.

L'interface affiche un **radar superposé « Déclaré (CV) vs Démontré (test) »** par compétence : le recruteur voit d'un coup d'œil les compétences surévaluées.

2.6 Le rapport IA

Principe clé : le **code calcule tous les chiffres** (θ , niveaux, scores, gap — aucun risque d'hallucination) ; l'**IA locale rédige l'analyse qualitative** : synthèse, niveau technique, qualité du raisonnement, cohérence CV, verdict (RECRUTER / À APPROFONDIR / REJETER) justifié. Le recruteur peut tout vérifier : bouton « Voir les réponses » (chaque QCM avec le choix du candidat vs la bonne réponse, chaque rédaction avec son score).

2.7 Sécurité et anti-triche

Contrôle d'accès — trois verrous successifs :

1. **Compte** : le candidat doit être connecté à *son* compte (celui lié au CV) ; un administrateur connecté peut aussi ouvrir le lien (test/aperçu).
2. **PIN** : code à 6 chiffres, à usage unique, envoyé par e-mail, exigé au démarrage et revalidé côté serveur à chaque réponse.
3. **Fenêtre de dates** : avant l'ouverture ou après la limite, l'accès est refusé.

Anti-triche — traçabilité, pas de sanction automatique :

Risque	Contre-mesure
Partage des questions	Sous-ensemble aléatoire par candidat + options mélangées (permutation déterministe par session, remappée côté serveur)
Recherche externe pendant un QCM	Timer 90 s par question (temps écoulé = compté faux) ; temps de réponse enregistré (QCM difficile réussi en moins de 5 s = signalé)
Copier-coller (ChatGPT...)	Bloqué sur les questions et les réponses ; tentatives comptées
Texte injecté sans taper	Télémetrie clavier : frappes comptées vs longueur du texte
Sortie de l'écran du test	Plein écran obligatoire (annoncé et accepté sur l'écran des règles) ; chaque sortie et changement d'onglet est enregistré

Ces signaux alimentent un **score d'intégrité (0–100)** présenté au recruteur avec la liste des incidents. **Choix de conception assumé** : le système ne bloque jamais automatiquement le candidat (un rafraîchissement ou la touche Échap ne prouvent pas la triche) — il *trace et signale*, la décision reste *humaine*. C'est le modèle des outils professionnels de surveillance d'examen, et la position la plus défendable juridiquement.

3 Internet, confidentialité et RGPD

3.1 Qu'est-ce qui utilise Internet ? (audit du code)

Composant	Où il s'exécute	Internet ?
Génération des questions (Mistral 7B)	Ollama, sur la machine	Non
Notation sémantique (BGE-M3)	En mémoire, sur la machine	Non
Test adaptatif (catsim)	Bibliothèque Python locale	Non
Rapport IA	Ollama, sur la machine	Non
Base de données	PostgreSQL local	Non
Envoi des e-mails d'invitation	SMTP	Oui (<i>seul flux</i>)

Le **seul flux sortant** est l'e-mail d'invitation : adresse du candidat, prénom, titre du poste, lien, PIN, dates. **Aucun contenu de CV, aucune réponse, aucun résultat ne quitte jamais la machine.**

Recommandation production : remplacer le SMTP actuel (Gmail) par le serveur mail interne de l'entreprise — une variable d'environnement à changer, aucun code.

À noter : une première version du module d'entretien reposait sur une API cloud (Groq) ; elle a été **entièrement supprimée** du projet (code, tables, clé API) pour respecter l'interdiction des API externes. Preuve : `grep -ri groq backend/` → 0 résultat.

3.2 Analyse RGPD

Principe RGPD	Réponse du module
Minimisation des données	Le LLM ne reçoit que le titre du poste et les compétences de l'offre — jamais le CV ni l'identité.
Pas de transfert hors machine	Tout le traitement IA est local (Ollama + BGE-M3). Aucune donnée candidat n'est envoyée à un tiers.
Information préalable	Écran des règles avant le test : le candidat est informé (plein écran, enregistrement des sorties, analyse du clavier, timer) et clique pour accepter avant de commencer.
Proportionnalité de la surveillance	Pas de webcam, pas de micro, pas de capture d'écran — uniquement des signaux techniques, et aucune décision automatique.
Décision non automatisée (art. 22)	Le système <i>assiste</i> : le recruteur consulte les réponses brutes et décide seul.
Droit d'accès / effacement	Réponses consultables ; suppression d'une évaluation en un clic (cascade session + résultats).
Sécurité d'accès	Triple verrou (compte + PIN à usage unique + fenêtre de dates) ; endpoints recruteur protégés par authentification et rôle.

À formaliser côté entreprise avant production : durée de conservation des sessions/résultats (ex. purge à 12 mois) ; mention de l'évaluation dans la politique de confidentialité ; SMTP interne.

3.3 Questions probables et réponses

- « **Pourquoi l'IRT plutôt qu'un simple score ?** » Le niveau estimé est indépendant des questions posées : test plus court (~10 questions), équitable entre candidats ; c'est la méthode des tests standardisés.
- « **Comment garantir la qualité des questions générées ?** » Paliers de difficulté imposés, distracteurs plausibles obligatoires, auto-vérification par le modèle ; en dernier ressort le recruteur voit toutes les questions ; et le modèle local est remplaçable par un plus performant (une variable d'environnement).
- « **Et si le candidat triche ?** » La triche est rendue difficile (questions uniques, options mélangées, timer, copier-coller bloqué), détectable (télémétrie clavier, temps de réponse, sorties d'écran) et visible (score d'intégrité). La sanction reste humaine — choix éthique et juridique.
- « **Quelles données personnelles, et où ?** » CV et réponses : PostgreSQL local. Traitement IA : local. Seul envoi externe : l'e-mail d'invitation.
- « **Quelle est la contribution originale ?** » Le **Reality Gap Score** : croiser automatiquement le *déclaré* (CV parsé par le pipeline NLP) et le *démontré* (test IRT + notation sémantique) pour produire un indice de cohérence du CV, avec radar par compétence et score de matching ajusté.

3.4 Limites (honnêteté scientifique)

- Qualité du modèle local** : Mistral 7B produit occasionnellement une question discutable malgré les filtres (~1/16 observé). Mitigation : vérification humaine possible ; modèle remplaçable sans changer le code.
- Première génération lente** (~5–8 min par offre) — mitigée par l'arrière-plan, l'invitation différée et le cache par offre.
- Niveau déclaré dérivé** : les CV n'indiquent presque jamais un niveau chiffré (1 % des cas mesurés) ; la formule de dérivation est transparente mais reste une heuristique.

4. **Anti-triche web** : un second appareil ou une tierce personne restent indétectables par un navigateur — d'où le score d'intégrité et la contre-vérification humaine en entretien final.

Document généré le 11 juillet 2026 — branche `feature/reality-gap-score`.